WSP4Rec 研究报告

直接权重编辑在协同推荐中的有效性、分布性影响与标题信息作用

研究日期：2026 年 11 月 4 日 | 阶段：首轮受控实证研究 | 面向 WWW 短文选题决策

主要发现

在 MovieLens-100K 的固定离线协议中，Astra 可以通过无梯度权重变换改善推荐，但目前没有建立“读取权重具有独特优势”的证据。MSE-MF 的平均测试 NDCG@10 从 0.05801 提高到 0.07328；黑盒编辑与简单校准也能取得类似或更好的结果。

在更强的 BPR-MF 上，无标题 WSP 从 0.10441 变为 0.10490（相对变化 +0.46%），且三种子中有一个退化。标题辅助 WSP 为 0.10566，但预设标题平滑为 0.10580。结果支持继续研究编辑的信息条件，不支持宣布一种普遍优于常规推荐训练的新方法。

研究问题	本轮回答
RQ1 无文本是否有效	弱 MSE 基线可明显改善；强 BPR 基线收益小且不稳定。
RQ2 谁获益、谁受损	收益依赖用户活跃度与物品支持度；没有观察到低支持物品 Recall@10 的改善。
RQ3 标题是否有用	BPR 中存在小幅信号，且正确对应的表示优于打乱对应；尚未优于预设语义平滑。
RQ4 权重可见性是否必要	无标题条件下没有显示额外优势；标题条件的交互项为正，但仅有一次编辑发现轨迹。

建议定位：一项关于推荐权重编辑的可行性与归因研究。当前更有价值的发现是“常规校准能解释多少收益、标题邻居何时有用”，而非性能领先或通用冷启动能力。

实验协议与信息边界

固定基础推荐器与评估口径

943 名用户、1,682 部电影、100,000 条评分。每用户按时间排序，训练／验证／测试为 79,619／9,942／10,439 条；同时间戳按物品 ID 排序。这是每用户时间划分，不能解释为全局时间上的线上预测。物品目录来自固定 u.item 元数据。

评分≥4 作为正例。主指标为全目录 NDCG@10，辅指标 Recall@10、HitRate@10。验证排除所有训练交互，测试排除训练及验证交互；未观察物品作为候选不等于其真实不相关。测试共有 856 名用户有 eligible 正例，共 4,975 个正例。

模型是两字段 FM，等价于带偏置 MF，向量维度 16，共 44,626 个参数。MSE 与 BPR 分别调参。种子 42 上搜索学习率 0.003／0.01、weight decay 1e-5／0.001；上限 80 epoch、12 epoch 耐心值，验证 NDCG@10 选 checkpoint。再用选定超参数训练种子 43、44。BPR 正例为高评分，负例均匀采自未训练交互物品；低评分不直接作为负例。

MSE 三个种子的最优 checkpoint 均在第 3 epoch，运行至第 15 epoch 早停。因此这里只能称“ 按验证排序选出的 MSE 模型 ”，不能宣称已经充分收敛的评分预测解仍被显著改进。

条件	编辑者可见信息	相同反馈预算
WSP	结构、训练计数、真实参数	2 轮 × 每轮 4 候选
Blind	结构、训练计数；不可看真实参数	同上
WSP＋标题	WSP 信息＋标题与 Qwen 表示	同上
Blind＋标题	Blind 信息＋标题与 Qwen 表示	同上

每种训练目标的四个编辑条件使用独立 Astra 子代理。仅种子 42 用于发现与选择 recipe，之后固定迁移到种子 43、44，不再选择。所有候选从同一原始 checkpoint 出发；原模型始终可选。编辑使用缩放、支持度修正、范数调整、维度缩放或邻居平滑等代数操作，不进行梯度更新或数据拟合。

Blind 与 WSP 共用相对编辑接口，运行器可在内部使用私有权重。比较的是“ 编辑者能否观察权重 ”，不是“ 整个过程是否利用权重 ”。文本条件同时开放标题输入与基于 Qwen 的邻居算子，因此研究的是标题辅助流程的联合效应。

原始交互与测试标签不提供给编辑者；反馈仅包含自己的候选 ID 和验证分数，编辑范数保留在审计日志。子代理遵守显式文件白名单，但没有建立容器级文件系统隔离。全部选择、checkpoint、标题表示和代码哈希冻结后，统一进行一次测试报告。

总体结果与基线强度

表 1 三种子测试均值 ± 样本标准差；同一数据划分，编辑策略并非独立重复。

方法	MSE NDCG@10	BPR NDCG@10	MSE Recall	BPR Recall
原模型	0.05801 ± 0.00249	0.10441 ± 0.00070	0.05933	0.12498
Astra 读权重	0.07328 ± 0.00068	0.10490 ± 0.00202	0.07724	0.12455
Astra 黑盒	0.07544 ± 0.00075	0.10500 ± 0.00234	0.07973	0.12465
Astra 读权重＋标题	0.07534 ± 0.00043	0.10566 ± 0.00292	0.08014	0.12561
Astra 黑盒＋标题	0.07494 ± 0.00101	0.10511 ± 0.00202	0.07880	0.12417
预设校准	0.07494 ± 0.00101	0.10490 ± 0.00202	0.07880	0.12455
预设随机变换	0.07540 ± 0.00038	0.10452 ± 0.00158	0.07924	0.12489
预设标题平滑	0.05889 ± 0.00267	0.10580 ± 0.00101	0.06051	0.12664

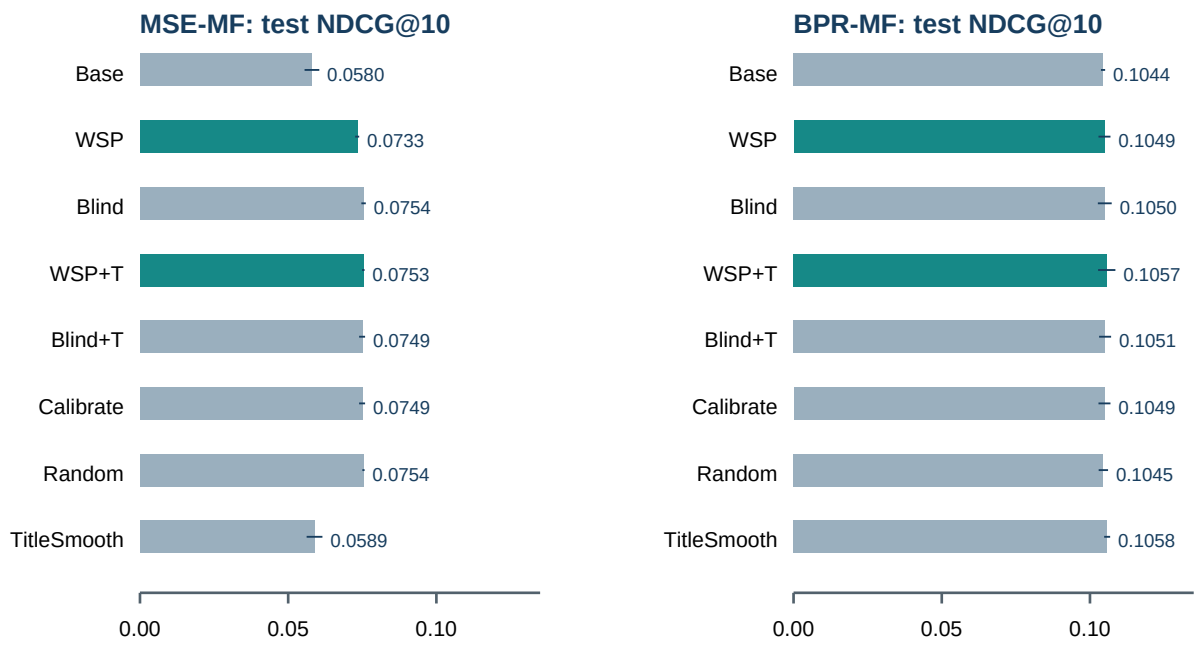

图 1 条为平均测试 NDCG@10，误差线为三种子标准差；不是置信区间。

上下文参照：热门推荐 NDCG@10=0.07365；验证选择的 EASE=0.12031。EASE 使用训练正例矩阵和四个正则化候选，不是同信息／同预算的编辑控制，也没有随机种子标准差。它说明本轮编辑后的 MF 仍未达到这一传统强参照。

无标题 BPR WSP 最终选择仅将物品偏置乘 0.5，和预设校准的选择完全一致，因此两者在三个种子上的测试结果逐一相同。不能将这个结果解释为 LLM 独有的权重推理能力。

RQ2 交互程度与连带损害

用户训练交互 tertile 阈值为 33、91；物品正训练支持 tertile 阈值为 8、43，零支持另列，共 71 个物品。计数并列使各桶大小不完全相等。这里的“ 冷 ”指低交互支持，不等于零历史冷启动。

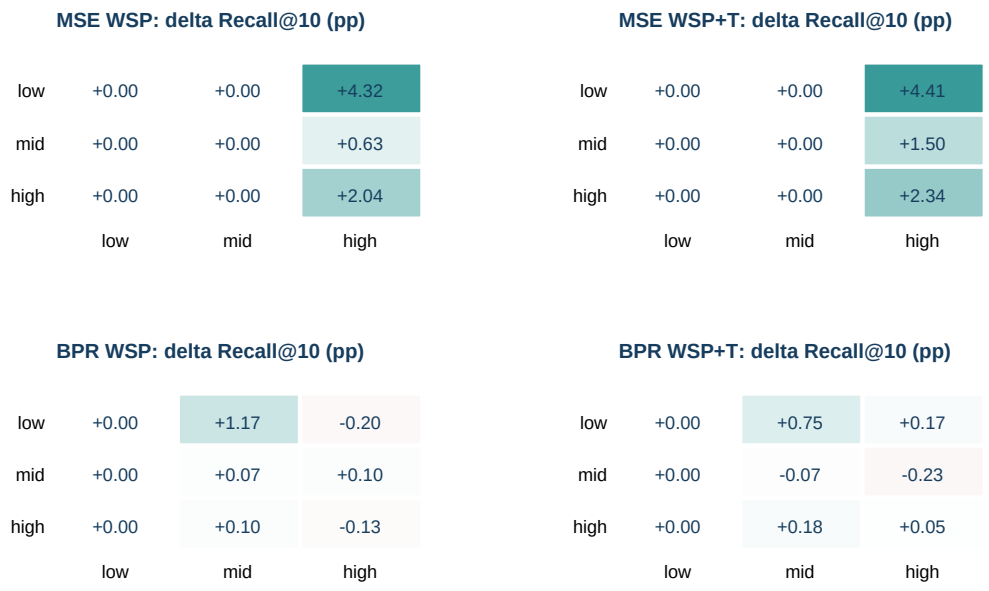

图 2 编辑相对原模型的 Recall@10 变化，单位百分点，平均于三个种子。行是用户活跃度，列是物品支持度；每格仍从全目录 Top10 计算，未在组内重排。

用户组	低支持物品 用户／正例	中支持物品 用户／正例	高支持物品 用户／正例
low	18 / 23	81 / 101	240 / 452
mid	28 / 38	120 / 194	281 / 1109
high	78 / 115	241 / 658	294 / 2272

在 WSP 与 WSP＋标题的最终策略中，低支持物品的 Recall@10 均没有改善。MSE 的可见提升集中在高支持物品；BPR 的变化较小并混合正负。低支持格的正例与用户数很少，因此结果不能用来证明 WSP 对所有长尾问题无效。

模型／编辑	平均改善用户比例	平均退化用户比例
MSE / WSP	19.2%	11.8%
MSE / WSP+T	21.1%	12.5%
BPR / WSP	13.3%	12.8%
BPR / WSP+T	18.1%	16.7%

改善／退化按用户 NDCG@10 的严格正负变化统计；其余用户保持不变。曝光与覆盖率也只在这 856 名有 eligible 正例的用户上计算，不是全用户公平性或线上体验结论。

RQ3 与 RQ4 标题作用和权重访问价值

文本特征固定为 Qwen3-Embedding-0.6B 对原始电影标题（保留年份）的 1,024 维末 token 表示，L2 归一化。它们不进入基础模型训练和在线推理，而用于编辑阶段的物品邻居平滑。标题相似性可能混合名称、年份、实体知识及预训练记忆，不能等同于纯内容语义。

三种子 NDCG 差值	MSE	BPR
无标题的权重可见收益：WSP - Blind	-0.00216	-0.00010
有标题的权重可见收益：WSP+T - Blind+T	0.00041	0.00055
上述两项之差：标题 × 权重访问交互	0.00257	0.00066
WSP+T - 预设标题平滑	0.01646	-0.00014
WSP+T：正确表示对应 - 打乱对应	0.00000	0.00316

BPR 标题辅助 WSP 选择“ 偏置乘 0.5＋全物品 15% 的五邻居文本平滑 ”。正确表示对应优于固定打乱对应，支持这一编辑对文本邻居对应有依赖；但单独预设标题平滑的平均测试分数更高。MSE 中打乱低支持邻居并不改变 Top10 分数，说明最终收益主要可由全局校准解释。

这里的打乱诊断仅替换编译器中的物品-表示对应，保持选定 recipe，不重新向编辑者提供乱标题，也没有再选择。它不能证明编辑者理解了电影语义。BPR 交互逐种子为 +0.00277、-0.00049、-0.00032，正均值主要来自发现种子 42。每条件仅一条发现轨迹，无编辑模型随机性置信区间。

固定种子下的配对不确定性

seed42 对原模型	Δ NDCG@10	配对用户 bootstrap 95% 区间
MSE / WSP	0.01345	[0.00734, 0.02004]
MSE / WSP+T	0.01557	[0.00936, 0.02210]
BPR / WSP	0.00220	[-0.00080, 0.00540]
BPR / WSP+T	0.00375	[0.00007, 0.00750]

2,000 次配对用户 bootstrap 仅条件于固定训练模型和划分，未校正多重比较；不能替代独立训练或编辑重复。BPR 无标题区间跨零，标题条件仅有单种子的边缘信号，不能据此写成稳定显著提升。

反馈预算与成本

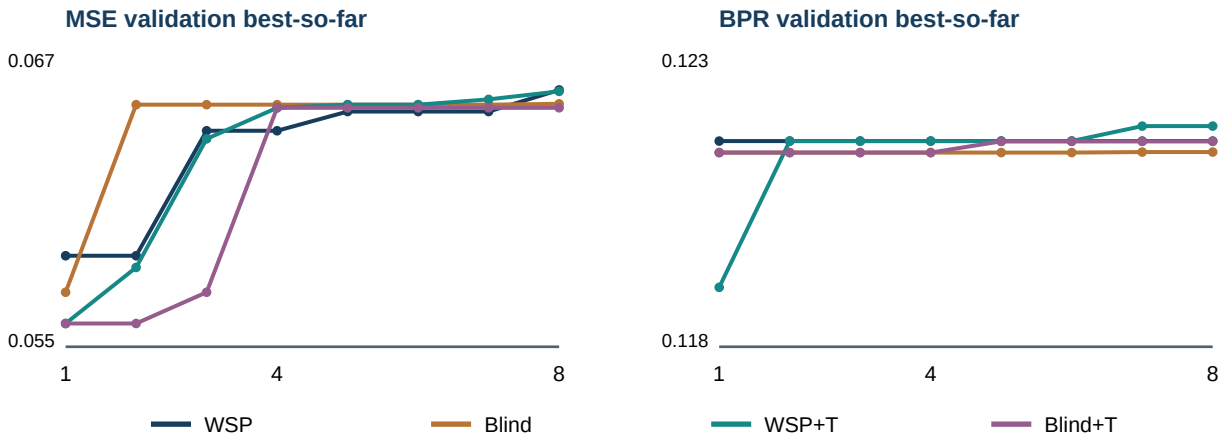

图 3 seed42 验证集的当前最优曲线，包含原模型回退。每轮四个候选一次性提出，只有第 4 次后向编辑者回传反馈；曲线不代表每次查询后都自适应。

资源或事件	本轮测量
基础模型训练	12 个试验；内部墙钟合计 23.51 秒；CPU、单线程
Astra 正式编辑	8 条轨迹、16 次生成回合、64 个候选反馈；失败候选 0
候选编译与验证	64 个候选的记录墙钟合计 9.45 秒
预设编辑对照	48 个唯一候选；额外重复执行 32 次；不是额外搜索预算
Qwen 标题提取	单 A100；墙钟 7.17 秒（载入 5.52、编码 1.65）；约 1.48 GB 峰值显存
Qwen 输入	1,682 个标题；19,396 个有效输入 token；一次性表示构建成本
最终测试报告	14.77 秒；统一已冻结策略＋固定打乱诊断
无法精确取得的字段	Astra 输入／缓存／输出 token、完整推理时长、逐次订阅金额；均记为 null

墙钟计时在操作函数内完成，不含 Python 导入、SSH、下载、传输和环境准备；不能称为端到端总成本。部分文本编辑回合另有首个工具动作到完成的观察时长，仅为局部时间。对照执行记录含重复计算，80 次物理评估合计 6.18 秒。研究开发与独立审查对话不摊入正式编辑成本。

已测计算任务均远低于单实验 1 小时上限；Astra 的完整单回合推理时长未由接口暴露。原生子代理使用当前订阅，没有可用逐次账单，不能写成零成本或与其他模型等成本。模型调用与 CPU/GPU 计算分别记录，未将订阅月费任意摊销。

证据边界与 WWW 短文建议

当前可以写入论文的结论

主张	证据与状态
无梯度编辑能改变离线推荐表现	支持，但限定为本数据、MF、操作接口和预算；MSE 改善更明显。
LLM 读取权重优于黑盒或简单校准	未建立。无标题条件权重访问未优于黑盒，BPR 选择与预设校准一致。
交互稀疏群体更受益	不支持普遍表述。低支持物品未见 Recall@10 改善，用户和中高支持物品变化异质。
标题能拓展 WSP 能力	有探索性信号，不能归因于 LLM 语义理解或宣称稳定优势。
方法低成本、可扩展到工业规模	未验证；目前只有小数据、结构化变换与不完整的模型用量数据。

限制

仅一个数据集、一个划分、16 维 MF；seed42 同时用于调参和编辑发现。三个训练种子不是三个独立编辑实验；没有因果操纵交互密度。随机控制搜索空间比 Astra 窄，预设控制不自适应，因此不能声称完整预算／搜索空间匹配。编辑算子预先规定，结果不是对任意权重编程能力的穷尽检验。

纯 ID 条件没有提供标题，但也没有对物品编号重新匿名排列，公开数据可能存在于 LLM 预训练中。零支持物品可在 BPR 中被采作负例，不构成真正新物品冷启动。低支持测试正例较少；离线未观察候选和实际曝光机制也限制了外推。

短文下一步应围绕一个主张补证据

建议优先重复“ 权重可见 vs 黑盒 ”的独立编辑轨迹，在另一个小型数据集／划分上验证；随后固定校准强度，再比较标题邻居和平滑算子，避免把校准收益混入语义收益。进一步移除标题年份、加入同格式乱配标题的完整编辑条件，以及与编辑空间一致的自适应非 LLM 搜索。这些属于后续研究，未在本轮测试结果上继续调参。

五维自审

贡献：归因与边界有价值，方法领先性不足。清晰度：参数、预算、分组和选择可复现。实验强度：有强参照与反例，独立编辑重复不足。评价完整性：四个 RQ 均有对应证据，单数据集与成本缺失仍是限制。方法合理性：编辑与训练分离；算子约束和仅指令隔离须如实说明。

复现与来源

复现入口

代码仓库：https://github.com/Jyonn/WSP4Rec
完整协议：study_protocol.json、study_amendments.json、editor_interface.json
公开汇总：reports/study_summary.json、reports/tables/、reports/evidence/
报告生成：scripts/build_study_report.py

训练与选择代码为 wsprec.study；测试封存和统一报告为 wsprec.finalize_study。原生 Astra 编辑不能用同一随机种子精确重放，故保留了全部 64 个候选、两轮反馈、数值诊断与最终 recipe，以便不重新调用模型时重现变换与结果。生成表格、图和 PDF 的脚本只读取现成结果，不再次评估测试集。

冻结清单 SHA256：08c243337145c7df49a8eb3f22320a4e24c7d6643e17c4f9261b281e3cfc9dfe

Qwen 固定版本：97b0c614be4d77ee51c0cef4e5f07c00f9eb65b3

参考来源

[1] Takehi et al. Sparks of Weight-Space Programming. 2026-11-02. https://rikiyat.github.io/blog/weight-space-programming/

[2] GroupLens. MovieLens 100K Dataset. https://grouplens.org/datasets/movielens/100k/

[3] Rendle et al. BPR: Bayesian Personalized Ranking from Implicit Feedback. UAI 2009. https://arxiv.org/abs/1205.2618

[4] Steck. Embarrassingly Shallow Autoencoders for Sparse Data. WWW 2019. https://arxiv.org/abs/1905.03375

[5] Lai et al. Better Late Than Never: Formulating and Benchmarking Recommendation Editing. 2024. https://arxiv.org/abs/2406.04553

[6] Qwen. Qwen3-Embedding-0.6B model card. https://huggingface.co/Qwen/Qwen3-Embedding-0.6B

[7] ACM Web 2027. Research Track Papers / short-paper format. https://www2027.thewebconf.org/research-track-papers/

这些来源分别支持原始 WSP 概念、数据来源、训练目标、EASE 方法、推荐编辑相关工作、标题表示实现及投稿格式；本报告所有性能数字来自本地实验，不来自上述来源。未将“ 推荐模型编辑 ”本身声称为首次提出。